Identification des faux billets par le Machine Learning

Arthur Gallois

Introduction

- **Problématique : Déterminer l'algorithme le plus efficace pour effectuer le traitement de faux billets**
  - Exactitude
  - Facilité d'implémentation
- **Données initiales (format .csv) :**
  - Liste de 1500 billets comprenant :
    - Les dimensions géométriques
    - L 'authenticité du billet
- **Logiciel utilisé : Python, via l'interface Jupyter Lab**

Méthodologie

- **Inspection initiale des données**
- **Test de quatre algorithmes différents, basés sur le Machine Learning**
  - Entraînement sur notre base de données
  - Calculs des différents indicateurs d'efficacité
- **Détermination du meilleur algorithme basé sur les performances calculées**

- **Algorithmes supervisés :**
  - Régression logistique
  - KNN
  - Forêt aléatoire
- **Algorithme non supervisé :**
  - K-means (clustering)

Inspection des données initiales

- **Pas de valeurs extrêmes**
  - Pas besoin de considérer des outliers potentiels pour nos futures études
- **Valeurs manquantes dans la colonne margin_low**
  - 31 valeurs sur les 1500 initiales
  - Méthode de remplacement de ces valeurs :
    - Mise en place d'une régression linéaire basée sur toutes les autres variables
      - Score R^2 : 0.617 (maximal)
      - Score MSE : 0.169
    - Mise à jour de la base de donnée en remplaçant les valeurs nulles par les valeurs calculées.

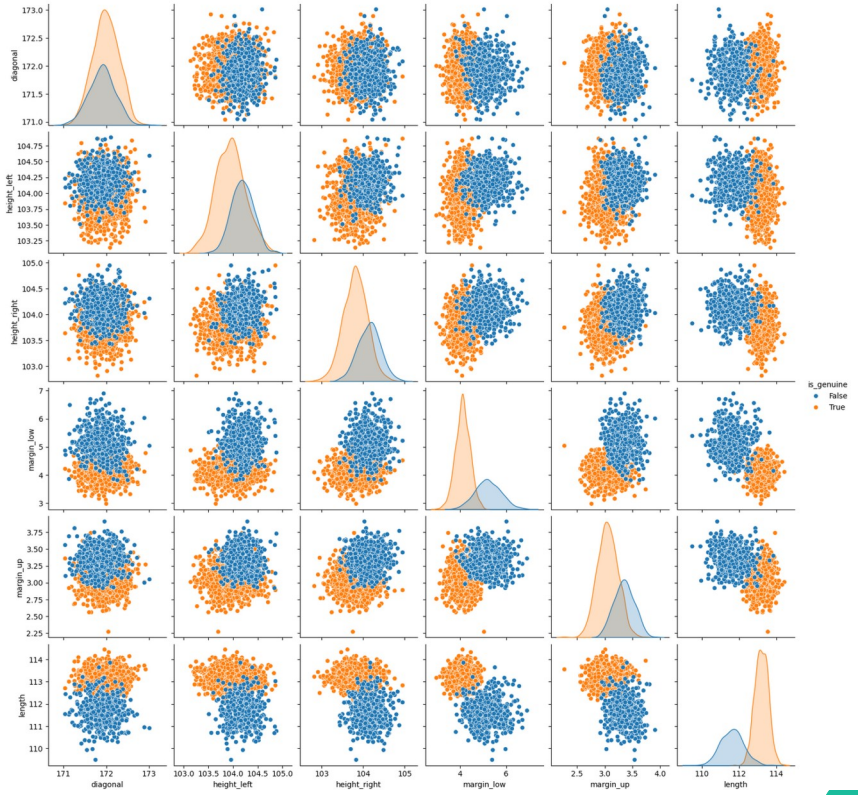

Données pertinentes de l’étude

- **Score R^2**
  - Variation de la variable cible expliquées par le modèle
    - 0 : Mauvais modèle
    - 1 : Modèle idéal
  - Moyenne effectuée après une validation croisée de 5 échantillons
- **Score MSE (Mean Squared error)**
  - Erreur des moindres carrés
  - Fonction de coût, détermine l’écart entre les prédictions du modèle et les valeurs cibles
    - Valeur proche de 0 : Bon modèle
- **Matrice de confusion**
  - Sous le format suivant :

Vrai positif (VP)	Faux négatif (FN)
Faux positif (FP)	Vrai négatif (VN)

  - Éléments à calculer :
    - Rappel : VP/(VP + FN), minimise les faux négatifs : Indicatif à privilégier dans notre cas !
    - Précision : VP/(VP + FP), minimise les faux positifs

Méthode 1 : Régression logistique

- **Régression linéaire, qui classifie les variables cibles en fonction d'un seuil défini.**
- **Un seuil de 0.5 (valeur par défaut) donne des valeurs optimales pour ce modèle**
  - Score R^2 : 0.990
  - MSE : 0.003
  - Score de rappel : 0.988
- **Bon modèle permettant de prédire avec précision l'authenticité du billet**

Échantillon	1		2		3		4		5	
Matrice de confusion	107	3	96	2	87	2	87	1	113	2
	0	190	2	200	0	211	2	210	0	185

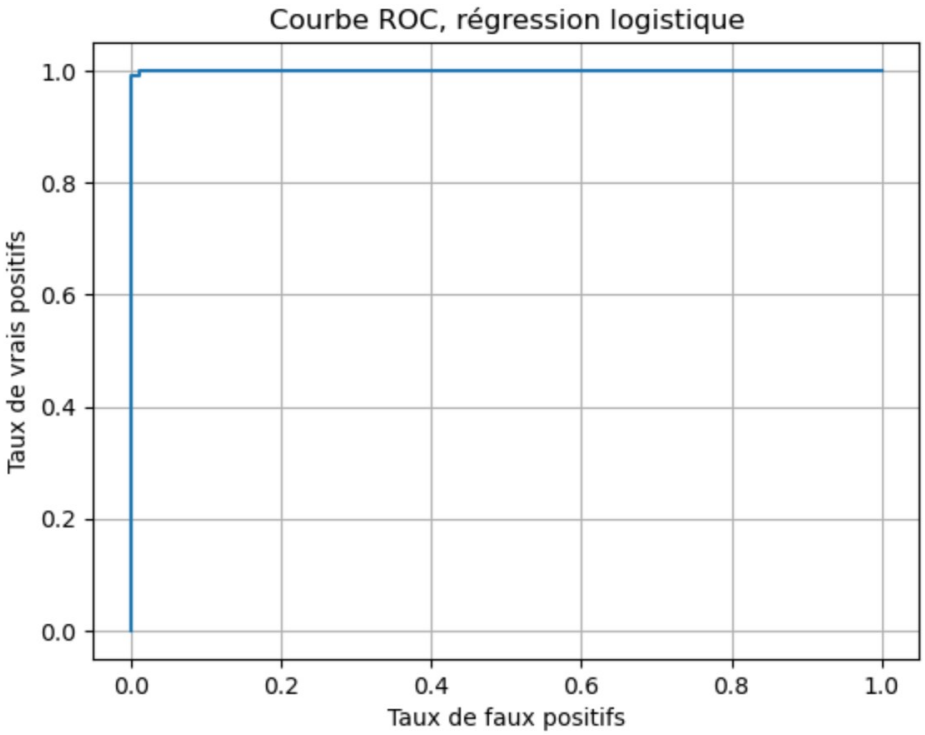

Méthode 2 : KNN

- **Méthode d'évaluation de la variable cible basé sur le nombre de voisins les plus proches et leurs catégorie**
- **Un nombre de voisins proches de 3 donne des valeurs optimales pour ce modèle**
  - Score R^2 : 0.991
  - MSE : 0.013
  - Score de rappel : 0.988
- **Une matrice de corrélations**
- **Bon modèle, mais reste inférieur à la régression logistique.**

Échantillon	1		2		3		4		5	
Matrice de confusion	106	4	96	2	87	2	87	1	113	2
	0	190	1	201	0	211	2	210	0	185

Méthode 3 : forêt aléatoire

- **Entraînement de prédicateurs faibles lors de nombreuses instances**
- **Détermination du nombre maximal d'estimateurs**
  - Objectif : réduire le biais du modèle
  - Plateau à 50 estimateurs

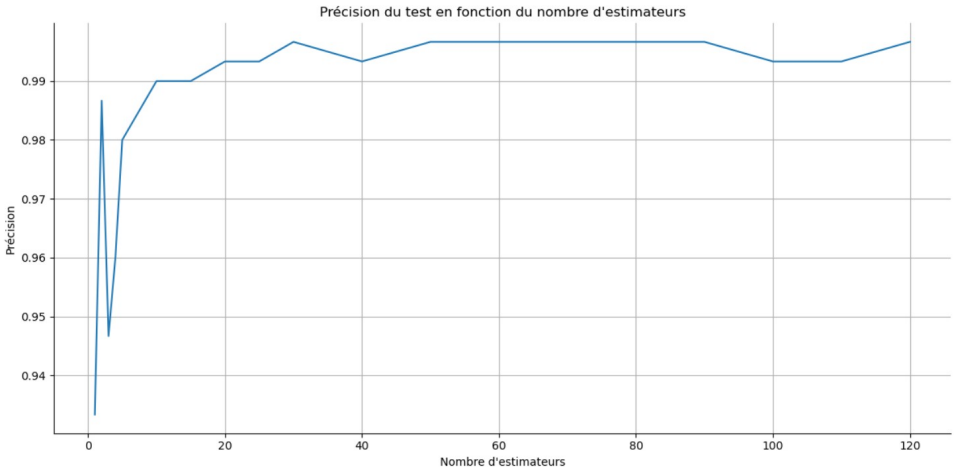

Méthode 3 : forêt aléatoire

- **Arbres de sélection créés, détaillant le procédé d'identification des billets**
- **Valeurs finales, basées sur la moyenne des prédictions créés :**
  - Score R^2 : 0.966
  - MSE : 0.007
  - Score de rappel : 0.985
- **Modèle correct mais ne minimisant pas les faux négatifs, inadapté pour notre étude**

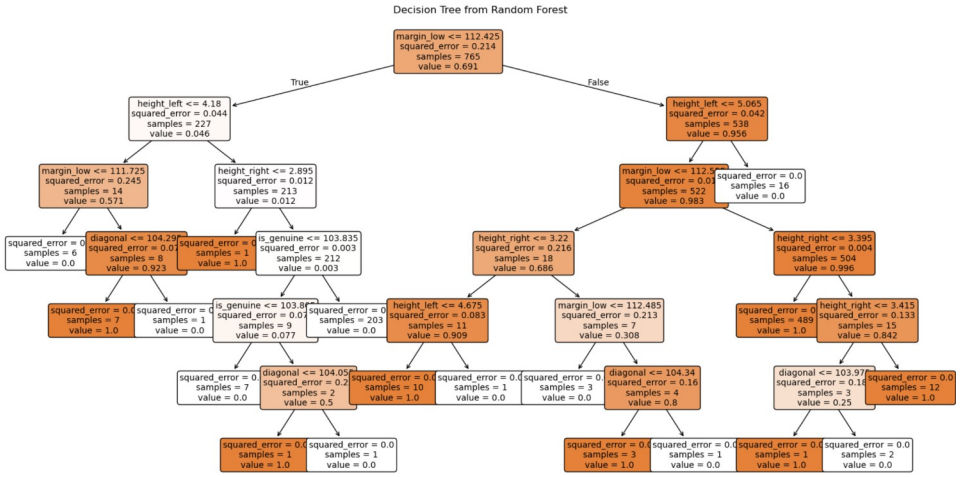

Échantillon	1		2		3		4		5	
Matrice de confusion	107	3	96	2	86	3	87	1	113	2
	1	189	2	200	0	211	2	210	2	183

Méthode 4 : K-means

- **Méthode non supervisée, classant les données dans un nombre prédéfini de clusters**
- **Calcul du nombre optimal de cluster par la méthode de la silhouette**
  - Minimiser l'inertie intra-cluster, tout en maximisant l'inertie inter-clusters
  - Nombre de clusters retenu : 2
- **Valeurs finales :**
  - Score R^2 : 0.936
  - MSE : 0.016
  - Score de rappel : 0.977
- **Bon modèle, mais inférieur aux autres**

Échantillon	1		2		3		4		5	
Matrice de confusion	104	6	95	3	83	6	85	3	111	4
	0	190	1	201	0	211	1	211	0	185

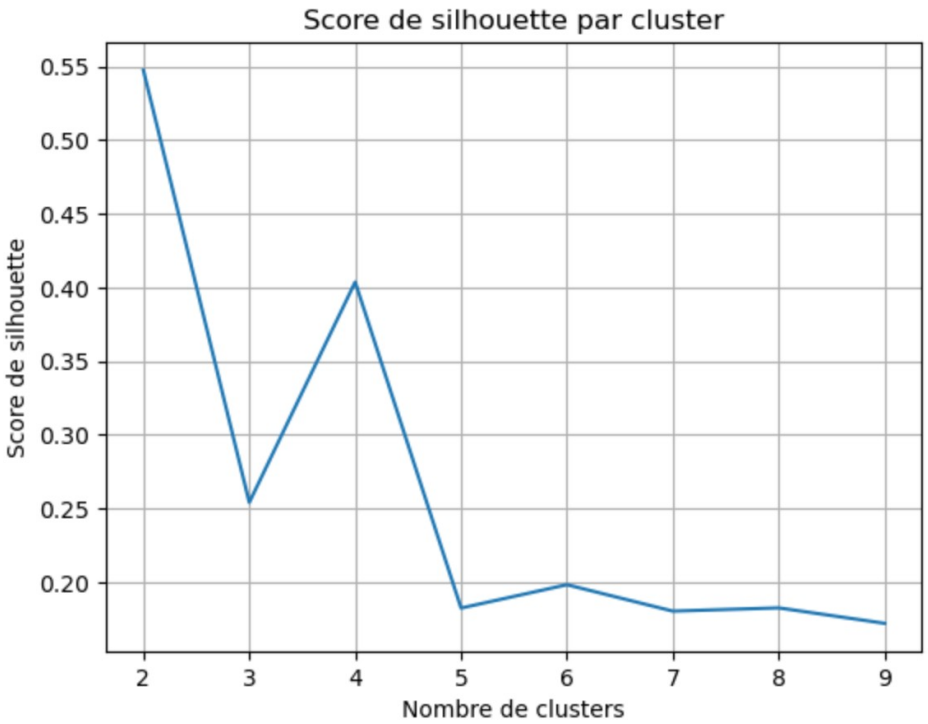

Conclusion

- **Une régression logistique est le modèle le plus adapté pour l'authentification de faux billets**
  - Meilleurs indicateurs
  - Facilité d'implémentation
  - Modèle supervisé : permet de réaliser une prédiction de phénomène statistique
- **Une démonstration sur un fichier plus volumineux peut être pertinente afin de vérifier la rapidité du modèle.**

Questions ?